R 语言编程：基于 tidyverse

第 13 讲　数据操作 III: 其它操作

张敬信

2022 年 12 月 1 日

哈尔滨商业大学

一. 按行汇总

- 通常的数据操作逻辑都是**按列方式**，这使得按行汇总并不容易
- `rowwise()` 为数据框创建**按行方式**，并不是真的改变数据框，只是创建了按行元信息，改变了数据框的操作逻辑
- **按行方式**可以理解为一种特殊的分组：每一行作为一组，执行的是“分组-汇总-合并”，速度较慢。要解除行化模式，用 `ungroup()`
- **按行方式**的一种巧妙的用途是批量建模（见 3.3.3）

```
df = readxl::read_xlsx("data/ExamDatas.xlsx")
```

```
rf = df %>%
  rowwise()
rf
#> # A tibble: 50 x 8
#> # Rowwise:
#>   class name   sex   chinese  math english moral scienc
#>   <chr> <chr>  <chr>   <dbl> <dbl>   <dbl> <dbl>   <dbl
#> 1 六 1 班 何娜   女         87    92      79     9
#> 2 六 1 班 黄才菊 女         95    77      75     8
#> 3 六 1 班 陈芳妹 女         79    87      66     9
#> # ... with 47 more rows
```

```r
rf %>%
  mutate(total = sum(chinese, math, english))
#> # A tibble: 50 x 9
#> # Rowwise:
#>   class name   sex   chinese  math english moral scienc
#>   <chr> <chr>  <chr>   <dbl> <dbl>   <dbl> <dbl>   <dbl>
#> 1 六 1 班 何娜   女         87    92      79     9
#> 2 六 1 班 黄才菊 女         95    77      75     8
#> 3 六 1 班 陈芳妹 女         79    87      66     9
#> # ... with 47 more rows
```

- c_across() 是为**按行方式**在选定的列范围汇总数据而设计的[1]，它没有提供 .fns 参数，只能选择列

```
rf %>%
  mutate(total = sum(c_across(where(is.numeric))))
#> # A tibble: 50 x 9
#> # Rowwise:
#>   class name   sex   chinese  math english moral scienc
#>   <chr> <chr>  <chr>   <dbl> <dbl>   <dbl> <dbl>   <dbl
#> 1 六 1 班 何娜   女         87    92      79     9
#> 2 六 1 班 黄才菊 女         95    77      75     8
#> 3 六 1 班 陈芳妹 女         79    87      66     9
#> # ... with 47 more rows
```

[1]若只是做按行求和或均值，直接用 rowSums()/rowMeans() 速度更快.

总结**逐行迭代**，除了 for 循环的四种做法：

```r
iris[1:4] %>%          # apply
  mutate(avg = apply(., 1, mean))
iris[1:4] %>%          # rowwise (慢)
  rowwise() %>%
  mutate(avg = mean(c_across()))
iris[1:4] %>%          # pmap
  mutate(avg = pmap_dbl(., ~ mean(c(...))))
iris[1:4] %>%          # asplit(逐行分割) + map
  mutate(avg = map_dbl(asplit(., 1), mean))
```

二. 窗口函数

- 汇总函数如 sum() 和 mean() 接受 n 个输入，返回 1 个值
- 而窗口函数是汇总函数的变体：接受 n 个输入，返回 n 个值。例如，cumsum()、cummean()、rank()、lead()、lag() 等。

1. 排名和排序函数

- 共有 6 个排名函数，只介绍最常用的 `min_rank()`[2]：默认从小到大排名

```
df %>%      # 按数学成绩从高到低排名次
  mutate(ranks = min_rank(-math)) %>%
  arrange(ranks)
#> # A tibble: 50 x 9
#>   class name   sex   chinese  math english moral scienc
#>   <chr> <chr>  <chr>   <dbl> <dbl>   <dbl> <dbl>   <dbl
#> 1 六 4 班 周婵   女         92    94      77    10
#> 2 六 4 班 陈丽丽 女         87    93      61     8
#> 3 六 1 班 何娜   女         87    92      79     9
#> # ... with 47 more rows
```

[2]相当于 `ties.method = "min"`.

2. 移位函数

lag(): 取前一个值，数据整体右移一位，相当于将时间轴滞后一个单位

lead(): 取后一个值，数据整体左移一位，相当于将时间轴超前一个单位

```
library(lubridate)
dt = tibble(
  day = as_date("2019-08-30") + c(0,4:6),
  wday = weekdays(day),
  sales = c(2,6,2,3),
  balance = c(30, 25, -40, 30)
)
```

```
dt %>%
  mutate(sales_lag = lag(sales),
         sales_delta = sales - lag(sales))
#> # A tibble: 4 x 6
#>   day         wday   sales balance sales_lag sales_delta
#>   <date>      <chr>  <dbl>   <dbl>     <dbl>       <dbl>
#> 1 2019-08-30 星期五     2      30        NA          NA
#> 2 2019-09-03 星期二     6      25         2           4
#> 3 2019-09-04 星期三     2     -40         6          -4
#> # ... with 1 more row
```

注：默认是根据行序移位，可用参数 order_by 设置根据某变量值大小顺序做移位。

3. 累计汇总

- base R 已经提供了 cumsum()、cummin()、cummax()、cumprod()
- dplyr 包又提供了 cummean()、cumany()、cumall()，后两者可与 filter() 连用选择行：
  - cumany(x)：用来选择遇到第一个满足条件之后的所有行
  - cumany(!x)：用来选择遇到第一个不满足条件之后的所有行
  - cumall(x)：用来选择所有行直到遇到第一个不满足条件的行
  - cumall(!x)：用来选择所有行直到遇到第一个满足条件的行

```r
x = c(1, 3, 5, 2, 2)
cumany(x >= 5)  # 从第一个出现 x>=5 选择后面所有值
#> [1] FALSE FALSE  TRUE  TRUE  TRUE
cumany(!x < 5)  # 同上，从第一个出现不满足 x<5 选择后面所有值
#> [1] FALSE FALSE  TRUE  TRUE  TRUE
cumall(x < 5)   # 依次选择值直到第一个 x<5 不成立
#> [1]  TRUE  TRUE FALSE FALSE FALSE
cumall(!x >= 5) # 同上，依次选择值直到第一个出现 x>=5
#> [1]  TRUE  TRUE FALSE FALSE FALSE
```

```r
dt %>%       # 选择第一次透支之后的所有行
  filter(cumany(balance < 0))
#> # A tibble: 2 x 4
#>   day         wday   sales balance
#>   <date>      <chr>  <dbl>   <dbl>
#> 1 2019-09-04 星期三     2     -40
#> 2 2019-09-05 星期四     3      30
dt %>%       # 选择所有行直到第一次透支
  filter(cumall(!(balance < 0)))
#> # A tibble: 2 x 4
#>   day         wday   sales balance
#>   <date>      <chr>  <dbl>   <dbl>
#> 1 2019-08-30 星期五     2      30
#> 2 2019-09-03 星期二     6      25
```

三. 滑窗迭代

- “窗口函数”术语来自 SQL，意味着逐窗口浏览数据，将某函数重复应用于数据的每个“窗口”。
- 窗口函数的典型应用包括滑动平均、累计和以及更复杂如滑动回归。

- slider 包提供了 slide_*() 系列函数实现滑窗迭代，其基本格式为：

```
slide_*(.x, .f, ..., .before, .after, .step, .complete)
```

- .x：为窗口所要滑过的向量
- .f：要应用于每个窗口的函数，支持 purrr 风格公式
- ...：用来传递 .f 的其他参数
- .before, .after：设置窗口范围当前元往前、往后几个元，可以取 Inf（往前、往后所有元）
- .step：每次函数调用，窗口往前移动的步长
- .complete：设置两端处是否保留不完整窗口，默认为 FALSE
- slider::slide_*() 系列函数与 purrr::map_*() 是类似的，只是将“逐元素迭代”换成了“逐窗口迭代”。

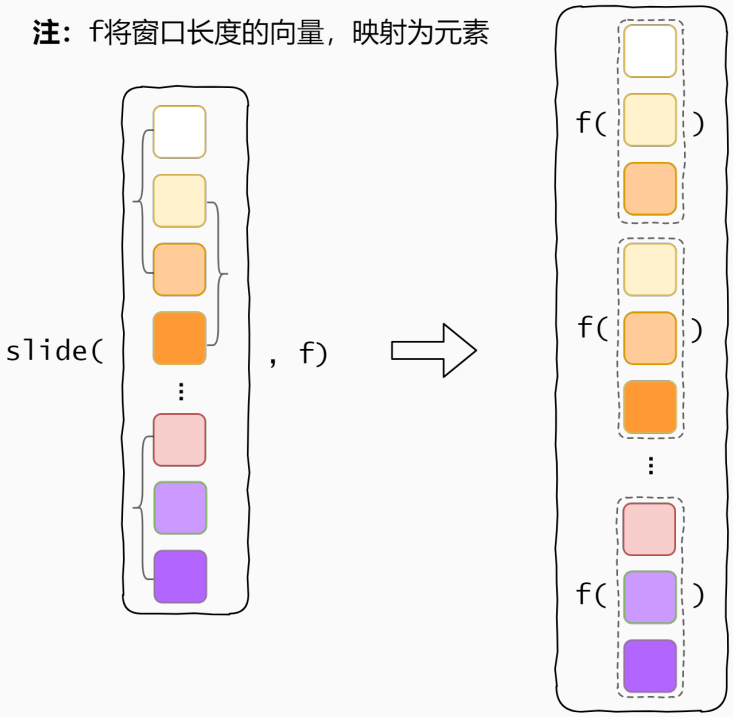

图 1： slide 滑窗迭代示意图

滑窗迭代的逻辑：先利用窗口参数正确设计并生成滑动窗口，每个滑动窗口是一个小向量，函数.f 是作用在一个小向量上，通过后缀控制返回结果类型，返回结果通常作为 mutate 的一列。

- 金融时间序列数据经常需要计算 3 日滑动平均

```
library(slider)
dt %>%
  mutate(avg_3 = slide_dbl(sales, mean,
                           .before = 1, .after = 1))
#> # A tibble: 4 x 5
#>   day         wday   sales balance avg_3
#>   <date>      <chr>  <dbl>   <dbl> <dbl>
#> 1 2019-08-30 星期五     2      30  4
#> 2 2019-09-03 星期二     6      25  3.33
#> 3 2019-09-04 星期三     2     -40  3.67
#> # ... with 1 more row
```

- 输出每个滑动窗口更便于理解该 3 日滑动平均是如何计算的：

```
slide(dt$sales, ~ .x, .before = 1, .after = 1)
#> [[1]]
#> [1] 2 6
#>
#> [[2]]
#> [1] 2 6 2
#>
#> [[3]]
#> [1] 6 2 3
#>
#> [[4]]
#> [1] 2 3
```

- 前面计算的并不是真正的 3 日，而是连续 3 个值的滑动平均。因为 `slide()` 默认是以行索引来滑动
- `slide_index(.x, .i, .f, ...)`：按索引向量`.i` 计算滑动平均，可根据“.i 的当前元 + 其前/后若干元”创建相应的`.x` 的滑动窗口

- 来看行索引和日期索引滑动窗口的区别

```
slide(dt$day, ~ .x, .before = 1, .after = 1)
#> [[1]]
#> [1] "2019-08-30" "2019-09-03"
#>
#> [[2]]
#> [1] "2019-08-30" "2019-09-03" "2019-09-04"
#>
#> [[3]]
#> [1] "2019-09-03" "2019-09-04" "2019-09-05"
#>
#> [[4]]
#> [1] "2019-09-04" "2019-09-05"
```

```
slide_index(dt$day, dt$day, ~ .x, .before = 1, .after = 1)
#> [[1]]
#> [1] "2019-08-30"
#>
#> [[2]]
#> [1] "2019-09-03" "2019-09-04"
#>
#> [[3]]
#> [1] "2019-09-03" "2019-09-04" "2019-09-05"
#>
#> [[4]]
#> [1] "2019-09-04" "2019-09-05"
```

- 计算 sales 真正的 3 日滑动平均

```
dt %>%
  mutate(avg_3 = slide_index_dbl(sales, day, mean,
                                 .before = 1, .after = 1))
#> # A tibble: 4 x 5
#>   day         wday   sales balance avg_3
#>   <date>      <chr>  <dbl>   <dbl> <dbl>
#> 1 2019-08-30 星期五     2      30  2
#> 2 2019-09-03 星期二     6      25  4
#> 3 2019-09-04 星期三     2     -40  3.67
#> # ... with 1 more row
```

四. 整洁计算

`tidyverse` 代码之所以“整洁、优雅”，是因为它内部采用了一套**整洁计算 (tidy evaluation)** 框架。

1. 数据屏蔽与整洁选择

- **整洁计算**的两种基本形式是：
  - 数据屏蔽：使得可以不用带数据框（环境变量）名字，就能使用数据框内的变量（数据变量），便于在数据集内计算值
  - 整洁选择：即各种选择列语法，便于使用数据集中的列
- 数据屏蔽内在的机制是先冻结表达式，然后注入函数，再恢复其计算。整洁计算已经为此做好了两种封装：
  - `{{ }}`（curly-curly 算符）：若只是传递，可将“冻结 + 注入”合成一步
  - `enquo()` 和 `!!`（引用与反引用）：不只是传递，而是在冻结和注入之间仍需要做额外操作

- 自定义函数时，想要像 tidyverse 那样整洁传递变量名，需要用到 {{ }} 将变量括起来：

```
var_summary = function(data, var) {
  data %>%
    summarise(n = n(), mean = mean({{var}}))
}
mtcars %>%
  group_by(cyl) %>%
  var_summary(mpg)
#> # A tibble: 3 x 3
#>     cyl     n  mean
#>   <dbl> <int> <dbl>
#> 1     4    11  26.7
#> 2     6     7  19.7
#> 3     8    14  15.1
```

若要传递多个整洁变量名，可以借助 across() 函数传递一个整洁选择：

```
group_count = function(data, var) {
  data %>%
    group_by(across({{var}})) %>%
    summarise(n = n())
}
group_count(mtcars, c(cyl, am))
#> # A tibble: 6 x 3
#> # Groups:   cyl [3]
#>     cyl    am     n
#>   <dbl> <dbl> <int>
#> 1     4     0     3
#> 2     4     1     8
#> 3     6     0     4
#> # ... with 3 more rows
```

- 若想用字符串形式传递变量名，在访问数据时需要借助.data[[var]]，这里.data 相当于代替数据集的代词

```
var_summary = function(data, var) {
  data %>%
    summarise(n = n(), mean = mean(.data[[var]]))
}
mtcars %>%
  group_by(cyl) %>%
  var_summary("mpg")
#> # A tibble: 3 x 3
#>     cyl     n  mean
#>   <dbl> <int> <dbl>
#> 1     4    11  26.7
#> 2     6     7  19.7
#> 3     8    14  15.1
```

- 还可用于对列名向量做循环迭代，比如对因子型各列计算各水平值频数：

```
mtcars[,9:10] %>%
  names() %>%
  map(~ count(mtcars, .data[[.x]]))
#> [[1]]
#>   am  n
#> 1  0 19
#> 2  1 13
#>
#> [[2]]
#>   gear  n
#> 1    3 15
#> 2    4 12
#> 3    5  5
```

- 将整洁选择作为函数参数传递，也需要用到 {{ }}

```
summarise_mean = function(data, vars) {
  data %>%
    summarise(n = n(), across({{vars}}, mean))
}
mtcars %>%
  group_by(cyl) %>%
  summarise_mean(where(is.numeric))
#> # A tibble: 3 x 12
#>     cyl     n   mpg  disp    hp  drat    wt  qsec    vs
#>   <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
#> 1     4    11  26.7  105.  82.6  4.07  2.29  19.1 0.909
#> 2     6     7  19.7  183. 122.   3.59  3.12  18.0 0.571
#> 3     8    14  15.1  353. 209.   3.23  4.00  16.8 0
```

- 若传递是多个列名构成的字符向量，则需要借助函数 `all_of()` 或 `any_of()`

```
vars = c("mpg", "vs")
mtcars %>% select(all_of(vars))
mtcars %>% select(!all_of(vars))
```

- 使用 {{ }} 或整洁选择同时修改列名

```
my_summarise = function(data, mean_var, sd_var) {
  data %>%
    summarise("mean_{{mean_var}}" := mean({{mean_var}}),
              "sd_{{sd_var}}" := mean({{sd_var}}))
}
mtcars %>%
  group_by(cyl) %>%
  my_summarise(mpg, disp)
#> # A tibble: 3 x 3
#>     cyl mean_mpg sd_disp
#>   <dbl>    <dbl>   <dbl>
#> 1     4     26.7    105.
#> 2     6     19.7    183.
#> 3     8     15.1    353.
```

```r
my_summarise = function(data, group_var, summarise_var) {
  data %>%
    group_by(across({{group_var}})) %>%
    summarise(across({{summarise_var}}, mean,
                     .names = "mean_{.col}"))
}
mtcars %>%
  my_summarise(c(am, cyl), where(is.numeric))
#> # A tibble: 6 x 11
#> # Groups:   am [2]
#>      am   cyl mean_mpg mean_disp mean_hp mean_~1 mean_w
#>   <dbl> <dbl>    <dbl>     <dbl>   <dbl>   <dbl>   <dbl
#> 1     0     4     22.9      136.    84.7    3.77    2.9
#> 2     0     6     19.1      205.   115.     3.42    3.3
#> 3     0     8     15.0      358.   194.     3.12    4.1
#> # ... with 3 more rows, 1 more variable: mean_carb <dbl
#> #   variable names 1: mean_drat, 2: mean_qsec, 3: mean_
```

- 对于字符串列名，同时修改列名

```
var_summary = function(data, var) {
  data %>%
    summarise(n = n(),
              !!enquo(var) := mean(.data[[var]]))
}
mtcars %>%
 group_by(cyl) %>%
 var_summary("mpg")
#> # A tibble: 3 x 3
#>     cyl     n   mpg
#>   <dbl> <int> <dbl>
#> 1     4    11  26.7
#> 2     6     7  19.7
#> 3     8    14  15.1
```

```r
var_summary = function(data, var) {
  data %>%
    summarise(n = n(),
              !!str_c("mean_", var) := mean(.data[[var]]))
}
mtcars %>%
 group_by(cyl) %>%
 var_summary("mpg")
#> # A tibble: 3 x 3
#>     cyl     n mean_mpg
#>   <dbl> <int>    <dbl>
#> 1     4    11     26.7
#> 2     6     7     19.7
#> 3     8    14     15.1
```

2. 引用与反引用

引用与反引用将冻结和注入分成两步，在使用上更加灵活：

- 用 enquo() 让函数自动引用其参数
- 用!! 反引用该参数

- 以自定义计算分组均值函数为例：

```
grouped_mean = function(data, summary_var, group_var) {
  summary_var = enquo(summary_var)
  group_var = enquo(group_var)
  data %>%
    group_by(!!group_var) %>%
    summarise(mean = mean(!!summary_var))
}
grouped_mean(mtcars, mpg, cyl)
#> # A tibble: 3 x 2
#>     cyl  mean
#>   <dbl> <dbl>
#> 1     4  26.7
#> 2     6  19.7
#> 3     8  15.1
```

- 要想修改结果列名，可借助 as_label() 从引用中提取名字

```
grouped_mean = function(data, summary_var, group_var) {
  summary_var = enquo(summary_var)
  group_var = enquo(group_var)

  summary_nm = str_c("mean_", as_label(summary_var))
  group_nm = str_c("group_", as_label(group_var))

  data %>%
    group_by(!!group_nm := !!group_var) %>%
    summarise(!!summary_nm := mean(!!summary_var))
}
```

```
grouped_mean(mtcars, mpg, cyl)
#> # A tibble: 3 x 2
#>   group_cyl mean_mpg
#>       <dbl>    <dbl>
#> 1         4     26.7
#> 2         6     19.7
#> 3         8     15.1
```

- 要传递多个参数可以用特殊参数`...`。比如，还想让用于计算分组均值的 `group_var` 可以是任意多个

```
grouped_mean = function(.data, .summary_var, ...) {
  summary_var = enquo(.summary_var)
  .data %>%
    group_by(...) %>%
    summarise(mean = mean(!!summary_var))
}
```

```
grouped_mean(mtcars, disp, cyl, am)
#> # A tibble: 6 x 3
#> # Groups:   cyl [3]
#>     cyl    am  mean
#>   <dbl> <dbl> <dbl>
#> 1     4     0 136.
#> 2     4     1  93.6
#> 3     6     0 205.
#> # ... with 3 more rows
```

- ... 参数不需要做引用和反引用就能正确工作，但若要修改结果列名仍需要借助引用和反引用，但是要用 enques() 和!!!

```
grouped_mean = function(.data, .summary_var, ...) {
  summary_var = enquo(.summary_var)
  group_vars = enquos(..., .named = TRUE)
  summary_nm = str_c("avg_", as_label(summary_var))
  names(group_vars) = str_c("groups_", names(group_vars))
  .data %>%
    group_by(!!!group_vars) %>%
    summarise(!!summary_nm := mean(!!summary_var))
}
```

```
grouped_mean(mtcars, disp, cyl, am)
#> # A tibble: 6 x 3
#> # Groups:   groups_cyl [3]
#>   groups_cyl groups_am avg_disp
#>        <dbl>     <dbl>    <dbl>
#> 1          4         0    136.
#> 2          4         1     93.6
#> 3          6         0    205.
#> # ... with 3 more rows
```

- 参数... 还可以传递表达式

```
filter_fun = function(df, ...) {
  filter(df, ...)
}
mtcars %>%
  filter_fun(mpg > 25 & disp > 90)
#>                mpg cyl  disp  hp drat   wt qsec vs am g
#> Porsche 914-2 26.0   4 120.3  91 4.43 2.14 16.7  0  1
#> Lotus Europa  30.4   4  95.1 113 3.77 1.51 16.9  1  1
```

- 最后看一个自定义绘制散点图的模板函数

```
scatter_plot = function(df, x_var,y_var) {
  x_var = enquo(x_var)
  y_var = enquo(y_var)
  ggplot(data = df, aes(x = !!x_var, y = !!y_var)) +
    geom_point() +
    theme_bw() +
    theme(plot.title = element_text(lineheight = 1,
                                    face = "bold",
                                    hjust = 0.5)) +
    geom_smooth() +
    ggtitle(str_c(as_label(y_var), " vs. ", as_label(x_var)
}
```

```
scatter_plot(mtcars, disp, hp)
```

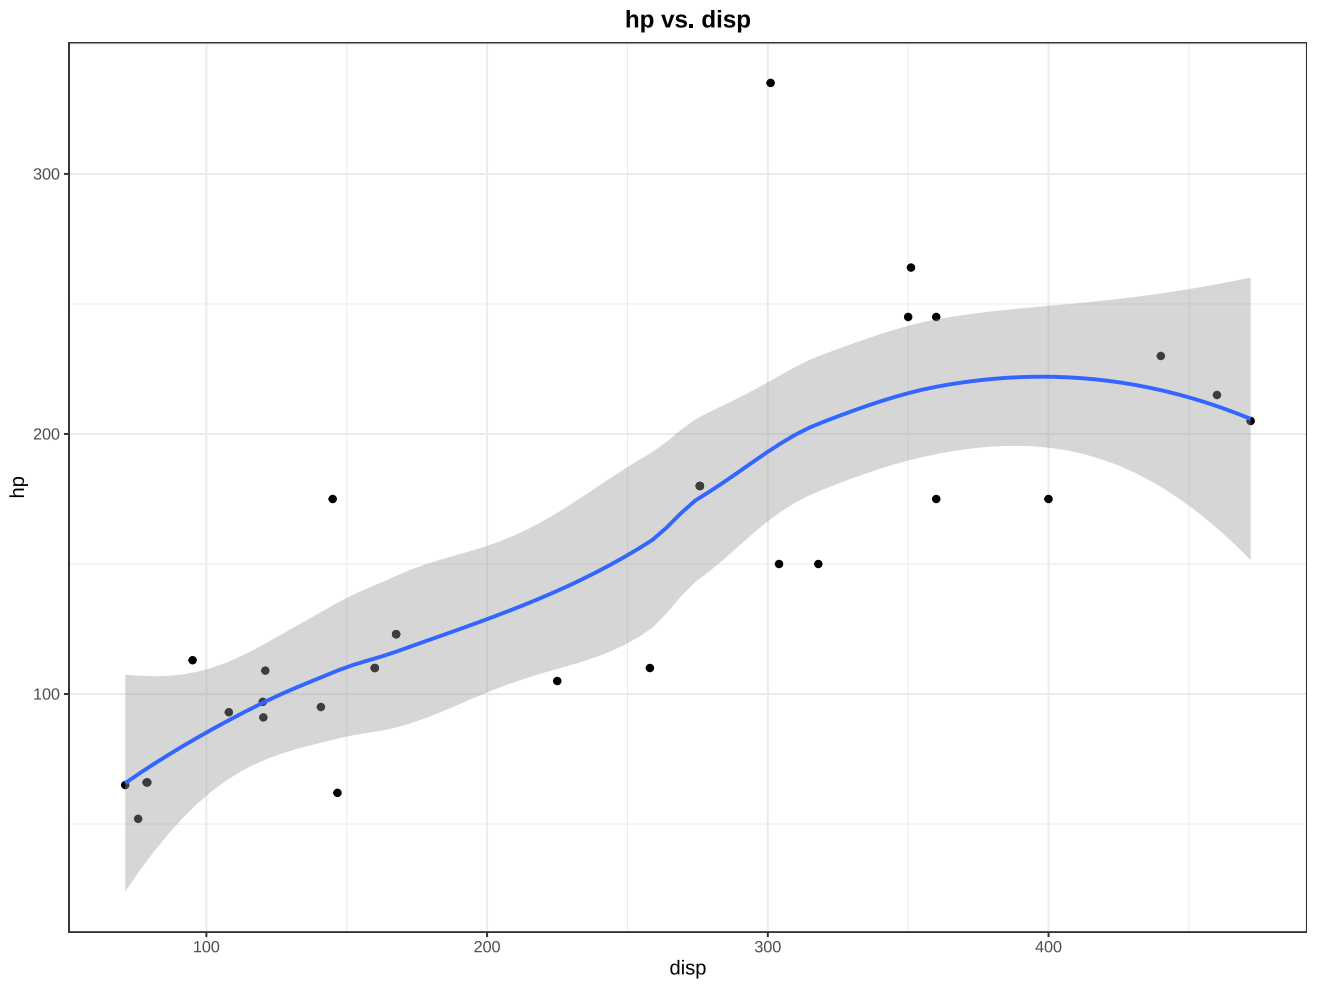

本篇主要参阅 (张敬信, 2022), (Lionel Henry, 2020), 以及包文档、R-Bloggers 文章，模板感谢 (黄湘云, 2021), (谢益辉, 2021).

参考文献

Lionel Henry, H. W. (2020). *Tidy evaluation*. tidyverse.org.

张敬信 (2022). *R* 语言编程：基于 *tidyverse*. 人民邮电出版社, 北京.

谢益辉 (2021). *rmarkdown: Dynamic Documents for R*.

黄湘云 (2021). *Github: R-Markdown-Template*.