# R 语言编程: 基于 tidyverse

第 15 讲 ggplot2 绘图 I

张敬信

2022年12月6日

哈尔滨商业大学

## 一. ggplot2 概述

ggplot2 是最流行的 R 可视化包,基于图层化语法: 图形是一层一层的图层叠加而成,先进的绘图理念、优雅的语法代码、美观大方的生成图形,一直以来是 R 语言的名片。

## 1. ggplot2 绘图语法是从数据产生图形的一系列语法:

选取整洁数据将其映射为几何对象(如点、线等),几何对象具有美学特征(如坐标轴、颜色等),若需要则对数据做统计变换,调整标度,将结果投影到坐标系,再根据喜好选择主题。

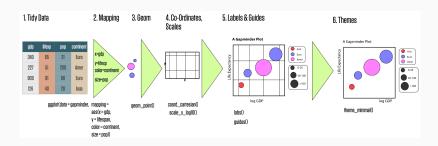


图 1: ggplot2 绘图流程

### ggplot 的语法包括 10 个部件:

- 数据 (data)
- 映射 (mapping)
- 几何对象 (geom)
- 标度 (scale)
- 统计变换 (stats)
- 坐标系 (coord)
- 位置调整 (Position adjustments)
- 分面 (facet)
- 主题 (theme)
- 输出 (output)

其中前 3 个是必须的, 其他部件 ggplot2 会自动帮你做好它认为"最优"的配置, 当然也都可以手动定制。

#### ggplot2 基本绘图模板:

```
ggplot(data = <DATA>,
       mapping = aes(<MAPPINGS>)) +
       <GEOM FUNCTION>(
                         mapping = aes(<MAPPINGS>),
                         stat = \langle STAT \rangle.
                         position = <POSITION>) +
       <SCALE_FUNCTION> +
       <COORDINATE FUNCTION> +
       <FACET FUNCTION> +
       <THEME FUNCTION>
```

注意:添加图层的加号只能放在行尾,而不能放在下一行行头。

### 二. 数据、映射、几何对象

## 1. 数据 (data)

■ 用于绘图的数据,需要是整洁的数据框

#> # ... with 231 more rows

```
library(tidyverse)
```

■ 用 ggplot()创建一个坐标系统,先只提供数据,此时只是创建了一个空的图形

ggplot(data = mpg)

# 2. 映射 (mapping)

- aes(): 美学映射, 就是将数据集中的变量数据映射(关联)到相应的图形属性
- **映射**:指明了变量与图形所见元素之间的联系,告诉 ggplot 图形元素 想要关联哪个变量数据
- 最常用的映射 (美学) 有:

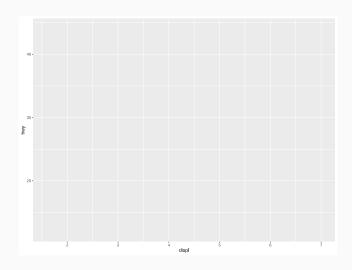
x: x 轴y: y 轴

color: 颜色
 size: 大小
 shape: 形状
 fill: 填充

■ alpha:透明度

■ 最需要的美学是 x 和 y, 分别映射到变量 displ 和 hwy, 再将美学 color 映射到 drv<sup>1</sup>, 此时图形就有了坐标轴和网格线:

<sup>&</sup>lt;sup>1</sup>也可以用 theme()函数定制自己的主题,更多的主题还有 ggthemes, ggpubr 包,其中包含一些顶级期刊专用绘图主题.



- 映射不是直接为出现在图形中的颜色、外形、线型等设定特定值,而是建立数据中的变量与可见的图形元素之间的联系
- 经常将图形的美学 color, size 等映射到数据集的分类变量,以实现不同分组用不同的美学来区分
- 若要为美学指定特定值,比如 color = "red",是不能放在映射 aes()中的

# 3. 几何对象 (Geometric)

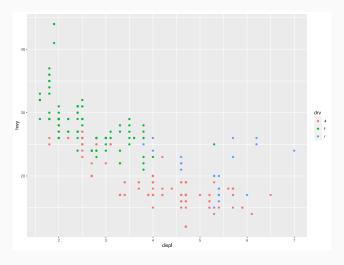
每个图形都是采用不同的视觉对象来表达数据,称为是"几何对象"。不同类型的"几何对象"从不同角度来表达数据,如散点图、平滑曲线、折线图、条形图、箱线图等。

ggplot2 提供了 50 余种"几何对象",不同的几何对象支持的美学会有些不同,但均以 geom\_xxxx()的方式命名,常用的有:

- geom\_point(): 散点图
- geom\_line(): 折线图
- geom\_smooth(): 光滑(拟合)曲线
- geom\_bar()/geom\_col(): 条形图
- geom\_histogram(): 直方图
- geom\_density(): 概率密度图
- geom\_boxplot(): 箱线图
- geom\_abline()/geom\_hline()/geom\_vline: 参考直线

■ 要绘制几何对象,只需添加图层。绘制散点图:

```
ggplot(mpg, aes(displ, hwy, color = drv)) +
  geom_point()
```

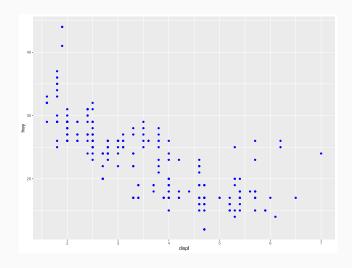


■ 美学映射也可以放在几何对象中,效果同上:

```
ggplot(mpg, aes(displ, hwy)) +
  geom_point(aes(color = drv))
```

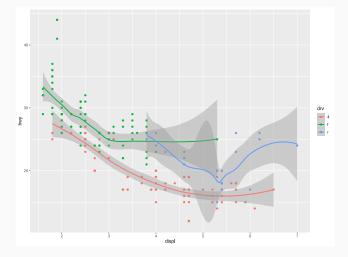
■ 为图形美学设置特定值,但注意不能放在映射 aes()中

```
ggplot(mpg, aes(displ, hwy)) +
  geom_point(color = "blue")
```

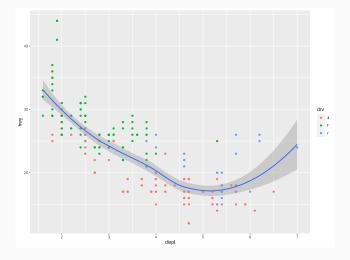


■ 图层是依次叠加的,再添加一个几何对象:光滑曲线,区分两种写法:

```
ggplot(mpg, aes(displ, hwy, color = drv)) +
  geom_point() +
  geom_smooth()
```



```
ggplot(mpg, aes(displ, hwy)) +
  geom_point(aes(color = drv)) +
  geom_smooth()
```



# 出现这种不同涉及 ggplot2"全局"与"局部"的约定:

- ggplot()中的数据和映射,是全局的,可供所有几何对象共用;
- 而位于"几何对象"中的数据和映射,是局部的,只供该几何对象使用;
- "几何对象"优先使用局部的,局部没有则用全局的。

# 关于分组美学 (group)

- 前面用 aes(color = drv) 将颜色映射到分类变量 drv, 实际上就是实现了一种分组, 对不同 drv 值的数据, 按不同颜色分别绘图
- 来看另一种情况,针对分省数据绘制人均 GDP 与年份之间的折线图, 若不区分省份,每个年份都对应 31 个省份人均 GDP 值

load("data/ecostats.rda")

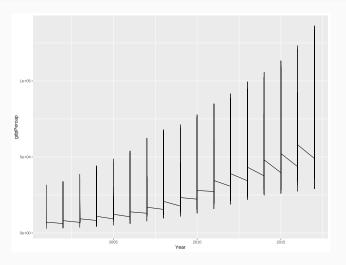
ecostats

#> # A tibble: 527 x 7

#> Region Year Electricity Investment Consumption Popul #> <chr> <int> <dbl> <dbl> <dbl> <dbl> #> 1 安徽 2001 360. 893. 2739 #> 2 北京 2001 400. 1513. 9057 #> 3 福建 2001 439. 1173. 4770

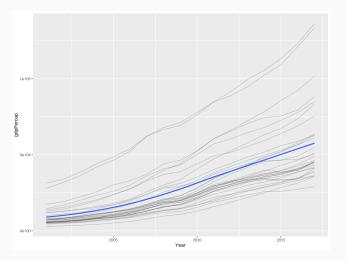
#> # ... with 524 more rows

ggplot(ecostats, aes(Year, gdpPercap)) +
 geom\_line()



■ 应该区分不同省份,这就需要显式地映射分组美学

```
ggplot(ecostats, aes(Year, gdpPercap)) +
  geom_line(aes(group = Region), alpha = 0.2) +
  geom_smooth(se = FALSE, size = 1.2)
```



## 三. 标度

■ 通常 ggplot2 会自动根据输入变量选择最优的坐标刻度方案,若要手动设置或调整,就需要用到标度函数,统一格式为:

# scale\_<MAPPING>\_<KIND>()

■ 标度函数控制几何对象中的标度映射:不只是 x, y 轴, 还有 color, fill, shape, size 产生的图例。它们是数据中的连续或 分类变量的可视化表示,这需要关联到标度,所以要用到映射

#### ■ 常用的标度函数有:

- scale\_\*\_continuous(): \* 为 x 或 y
- scale\_\*\_discrete(): \* 为 x 或 y
- scale x date()
- scale\_x\_datetime()
- scale\_\*\_log10(), scale\_\*\_sqrt(),
  scale\_\*\_reverse(): \* 为x或y
- scale\_\*\_gradient(), scale\_\*\_gradient2(): \* 为 color, fill 等
- scales 包提供了很多现成的设置刻度标签风格的函数

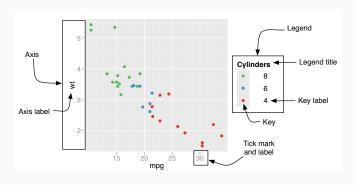


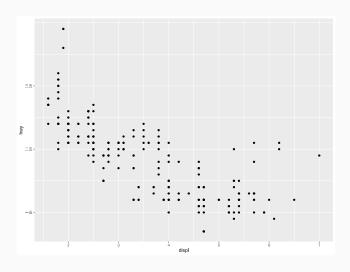
图 2: 图例与坐标轴的组件

### 1. 修改坐标轴刻度及标签

用 scale\_\*\_continuous() 修改连续变量坐标轴的刻度和标签:

- 参数 breaks 设置各个刻度的位置
- 参数 labels 设置各个刻度对应的标签

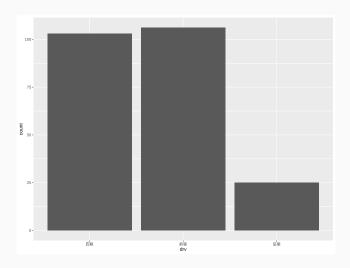
```
ggplot(mpg, aes(displ, hwy)) +
geom_point() +
scale_y_continuous(breaks = seq(15, 40, by = 10),
labels = c(" 一五"," 二五"," 三五"))
```



```
ggplot(mpg, aes(x = drv)) +
geom_bar() + # 条形图
scale_x_discrete(labels = c("4" = " 四驱", "f" = " 前驱",
```

"r" = " 后驱"))

用 scale\_\*\_discrete() 修改离散变量坐标轴的标签



#### 用 scale\_x\_date()设置日期刻度,参数:

- date\_breaks 设置刻度间隔
- date\_labels 设置标签的日期格式
- 借助 scales 包中的函数设置特殊格式,比如百分数 (percent)、科学计数法 (scientific)、美元格式 (dollar)等

```
economics
#> # A tibble: 574 x 6

#> date    pce    pop psavert vempmed vnemploy
#> <date>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>    2944

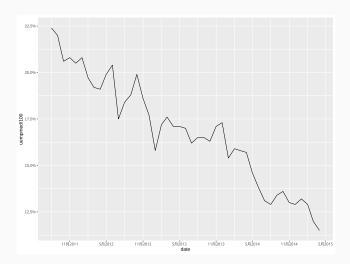
#> 2 1967-07-01 507. 198712 12.6 4.5 2944

#> 2 1967-08-01 510. 198911 12.6 4.7 2945

#> 3 1967-09-01 516. 199113 11.9 4.6 2958

#> # ... with 571 more rows
```

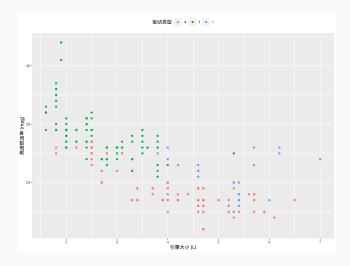
```
ggplot(tail(economics, 45), aes(date, uempmed / 100)) +
  geom_line() +
  scale_x_date(date_breaks = "6 months", date_labels = "%b%
  scale_y_continuous(labels = scales::percent)
```



## 2. 修改坐标轴标签、图例名及图例位置

- 用 labs()函数的参数 x, y, 或者函数 xlab(), ylab(), 设置 x 轴、y 轴标签
- 若前面已使用 color 美学,则可以在 labs()函数中使用参数 color 修改颜色的图例名
- 图例位置是在 theme 图层通过参数 legend.position 设置,可 选取值有"none", "left", "right", "bottom", "top".

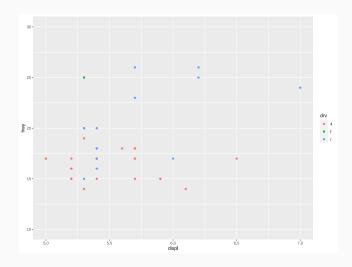
```
ggplot(mpg, aes(displ, hwy)) +
    geom_point(aes(color = drv)) +
    labs(x = " 引擎大小 (L)", y = " 高速燃油率 (mpg)",
        color = " 驱动类型") + # 或者
# xlab(" 引擎大小 (L)") + ylab(" 高速燃油率 (mpg)")
    theme(legend.position = "top")
```



## 3. 设置坐标轴范围

用 coord\_cartesian() 函数的参数 xlim 和 ylim,或者用 xlim(), ylim() 函数,设置 x 轴和 y 轴的范围:

```
ggplot(mpg, aes(displ, hwy)) +
geom_point(aes(color = drv)) +
coord_cartesian(xlim = c(5, 7), ylim = c(10, 30)) # 或者
# xlim(5, 7) + ylim(10, 30)
```



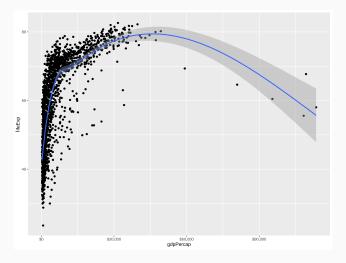
## 4. 变换坐标轴

变换数据再绘图,比如对数变换,坐标刻度也会变成变换之后的,这使得图形 不好理解。

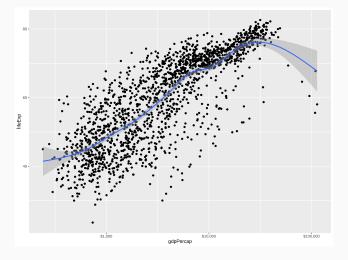
ggplot2 提供的坐标变换函数 scale\_x\_log10() 等是变换坐标系,能够在视觉效果相同的情况下,使用原始数据的坐标刻度

```
load("data/gapminder.rda")
p = ggplot(gapminder, aes(gdpPercap, lifeExp)) +
  geom_point() +
  geom_smooth()
```

## p + scale\_x\_continuous(labels = scales::dollar)

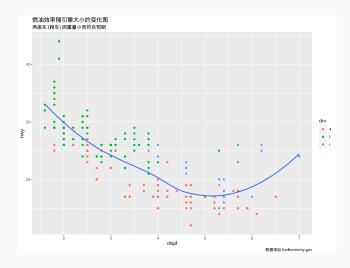


## p + scale\_x\_log10(labels = scales::dollar)



### 5. 设置图形标题

用 labs()函数的参数 title, subtitle, caption 设置标题、副标题、脚注标题 (默认右下角)



#### 图形标题默认居左, 若要居中, 需要加 theme 图层专门设置

```
p + theme(plot.title = element_text(hjust = 0.5), # 标题居 plot.subtitle = element_text(hjust = 0.5))
```



## 6. 设置 fill, color 颜色

数据的某个维度信息可以通过颜色来展示,颜色直接影响图形的美感。可以直接使用颜色值,但是更建议使用 RColorBrewer (调色板) 或 colorspace 包<sup>2</sup>。

## (1) 离散变量

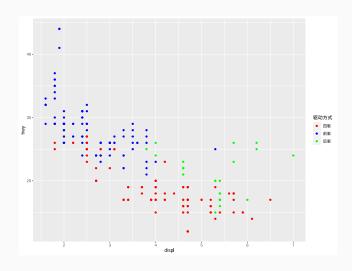
■ manual: 直接指定分组使用的颜色

hue: 通过改变色相 (hue) 饱和度 (chroma) 亮度 (luminosity) 来调整颜色

■ brewer: 使用 ColorBrewer 的颜色

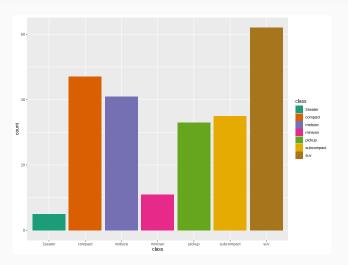
■ grey: 使用不同程度的灰色

<sup>&</sup>lt;sup>2</sup>查看所有可用的调色版: RColorBrewer::display.brewer.all(); 查看所有可用的 颜色空间: hcl\_palettes::hcl\_palettes(plot = TRUE).



```
ggplot(mpg, aes(x = class, fill = class)) +
geom_bar() +
scale_fill_brewer(palette = "Dark2") # 使用 Dark2 调色版
```

用 scale\_\*\_brewer()调用调色版中的颜色

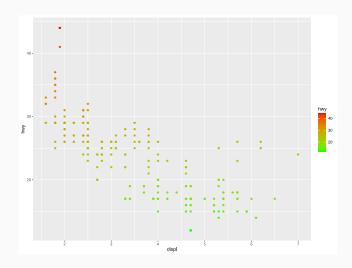


### (2) 连续变量

- gradient: 设置二色渐变色
- gradient2: 设置三色渐变色
- distiller: 使用 ColorBrewer 的颜色
- identity 使用 color 变量对应的颜色,对离散型和连续型都有效

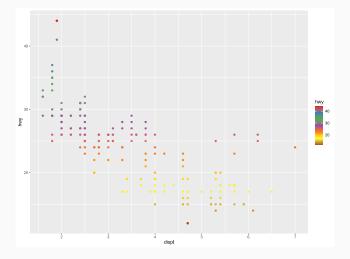
```
用 scale_color_gradient()设置二色渐变色
```

```
ggplot(mpg, aes(displ, hwy, color = hwy)) +
  geom_point() +
  scale_color_gradient(low = "green", high = "red")
```



```
ggplot(mpg, aes(displ, hwy, color = hwy)) +
  geom_point() +
  scale_color_distiller(palette = "Set1")
```

用 scale\_\*\_distiller()调用调色版中的颜色

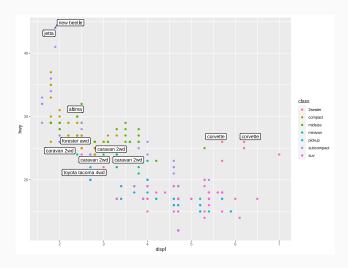


### 7. 添加文字标注

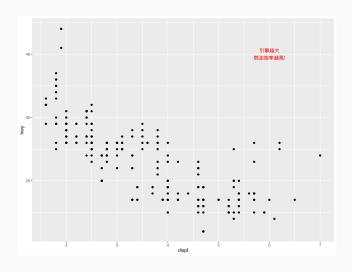
ggrepel 包提供了 geom\_label\_repel() 和 geom\_text\_repel() 函数,为图形添加文字标注。

首先要准备好标记点的数据,然后增加文字标注的图层,需要提供标记点数据, 以及要标注的文字给 label 美学,若来自数据变量,则需要用映射。

```
library(ggrepel)
best_in_class = mpg %>% # 选取每种车型 hwy 值最大的样本
group_by(class) %>%
slice_max(hwy, n = 1)
ggplot(mpg, aes(displ, hwy)) +
geom_point(aes(color = class)) +
geom_label_repel(data = best_in_class,
aes(label = model))
```



若要在图形某坐标位置添加文本注释,则用 annotate()函数,需要提供添加文本的中心坐标位置,和要添加的文字内容



### 四. 统计变换、坐标系、位置调整

## 1. 统计变换 (Statistics)

构建新的统计量进而绘图,称为"统计变换",简称"统计"。比如,条形图、 直方图都是先对数据分组,再计算分组频数绘图;平滑曲线用来根据数据拟合 模型,进而绘制模型预测值.....

ggplot2强大的一点就是,把统计变换直接融入绘图语法中,而不必先在外面对数据做统计变换,再回来绘图。

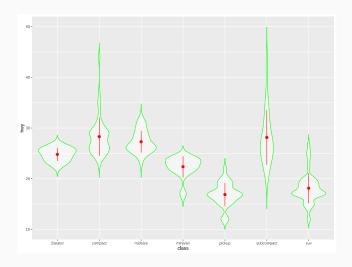
### ggplot2 提供了 30 多种 "统计", 均以 stat\_xxxx() 的方式命名:

- 可在几何对象函数 geom\_\*()中创建,通常直接使用后者即可:
  - stat\_bin(): geom\_bar(), geom\_freqpoly(),
    geom\_histogram()
  - stat\_bindot(): geom\_dotplot()
  - stat\_boxplot(): geom\_boxplot()
  - stat\_contour(): geom\_contour()
  - stat\_quantile(): geom\_quantile()
  - stat\_smooth(): geom\_smooth()
  - stat\_sum(): geom\_count()

- 不能在几何对象函数 geom\_\*() 中创建:
  - stat\_ecdf(): 计算经验累积分布图
  - stat\_function(): 根据 x 值的函数计算 y 值
  - stat\_summary(): 在 x 唯一值处汇总 y 值
  - stat\_qq(): 执行 Q-Q 图计算
  - stat\_spoke(): 转换极坐标的角度和半径为直角坐标位置
  - stat\_unique(): 剔除重复行

```
用 stat_summary() 做统计汇总并绘图
ggplot(mpg, aes(x = class, y = hwy)) +
geom_violin(trim = FALSE, alpha = 0.5, color = "green") ·
stat_summary(fun = mean,
fun.min = function(x) {mean(x) - sd(x)},
fun.max = function(x) {mean(x) + sd(x)},
```

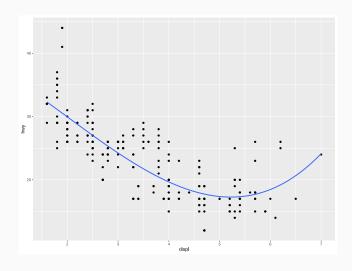
geom = "pointrange", color = "red")



用 stat\_smooth(), 与 geom\_smooth() 相同, 添加光滑曲线:

- method: 指定平滑曲线的统计函数,如 lm 线性回归,glm 广义线性回归,loess 多项式回归,gam 广义加法模型 (mgcv包),rlm 稳健回归 (MASS包)等
- formula: 指定平滑曲线的方程,如y~x,y~poly(x,2),y~log(x),需要与 method 参数搭配使用
- se: 设置是否绘制置信区间

```
ggplot(mpg, aes(displ, hwy)) +
geom_point() +
stat_smooth(method = "lm",
formula = y ~ splines::bs(x, 3),
se = FALSE) # 不绘制置信区间
```



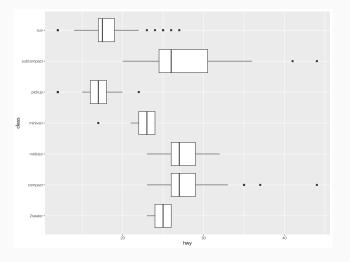
# 2. 坐标系 (Coordinante)

ggplot2 默认是直角坐标系 coord\_cartesian(), 常用的坐标系操作还有:

- coord\_flip(): 坐标轴翻转,即x轴与y轴互换,比如绘制水平条形图
- coord\_fixed(): 固定 ratio = y / x 的比例
- coord\_polar():转化为极坐标系,比如条形图转为极坐标系即为饼图
- coord\_trans(): 彻底的坐标变换,不同于 scale\_x\_log10()等
- coord\_map(), coord\_quickmap(): 与 geom\_polygon() 连 用,控制地图的坐标投影
- coord\_sf(): 与 geom\_sf() 连用,控制地图的坐标投影

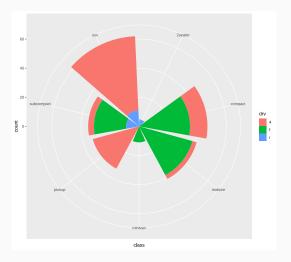
■ 坐标轴翻转,从水平图到竖直图:

```
ggplot(mpg, aes(class, hwy)) +
geom_boxplot() + # 箱线图
coord_flip() # 从竖直变成水平
```



■ 直角坐标下的条形图, 转化为极坐标下的风玫瑰图:

```
ggplot(mpg, aes(class, fill = drv)) +
  geom_bar() +
  coord_polar()
```

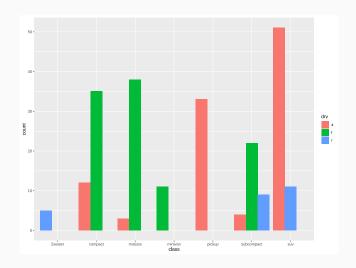


## 3. 位置调整 (Position adjustments)

#### 条形图中的条形位置调整:

- position\_stack(): 竖直堆叠
- position\_fill(): 竖直 (百分比) 堆叠,按比例放缩保证总高度为 1
- position\_dodge(), position\_dodge2(): 水平堆叠

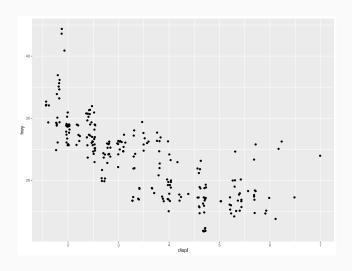
```
ggplot(mpg, aes(class, fill = drv)) +
  geom_bar(position = position_dodge(preserve = "single"))
# geom_bar(position = "dodge")
```



#### 散点图中的散点位置调整:

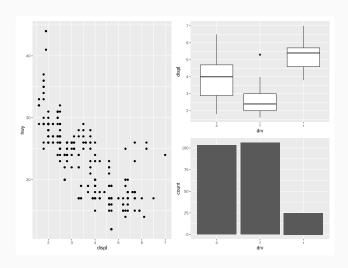
- position\_nudge(): 将散点移动固定的偏移量
- position\_jitter(): 给每个散点增加一点随机噪声 (抖散图)
- position\_jitterdodge(): 增加一点随机噪声并躲避组内的点, 特别用于箱线图 + 散点图

```
ggplot(mpg, aes(displ, hwy)) +
geom_point(position = "jitter") # 避免有散点重叠
```



■ 用 patchwork 包排布多个图形

```
library(patchwork)
p1 = ggplot(mpg, aes(displ, hwy)) +
   geom_point()
p2 = ggplot(mpg, aes(drv, displ)) +
   geom_boxplot()
p3 = ggplot(mpg, aes(drv)) +
   geom_bar()
p1 | (p2 / p3)
```



### 五. 分面、主题、输出

## 1. 分面 (Facet)

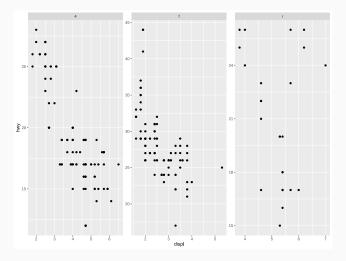
利用分类变量将图形分为若干个"面"(子图),即对数据分组再分别绘图,称为"分面"。

(1) facet\_wrap()

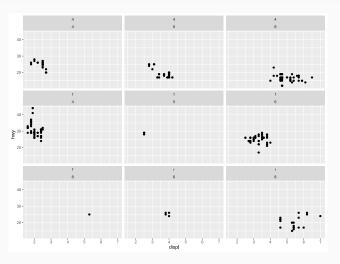
封装分面, 先生成一维的面板系列, 再封装到二维中。

- 分面形式: ~ 分类变量, ~ 分类变量 1 + 分类变量 2
- scales 参数设置是否共用坐标刻度, "fixed" (默认, 共用),"free" (不共用), 也可以用 free\_x, free\_y 单独设置
- 参数 nrow 和 ncol 可设置子图的放置方式

```
ggplot(mpg, aes(displ, hwy)) +
  geom_point() +
  facet_wrap(~ drv, scales = "free")
```



```
ggplot(mpg, aes(displ, hwy)) +
  geom_point() +
  facet_wrap(~ drv + cyl)
```

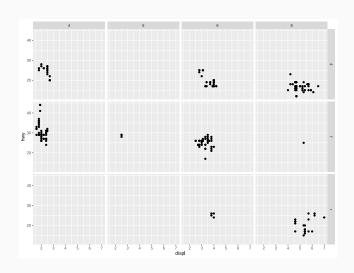


## (2) facet\_grid()

网格分面, 生成二维的面板网格, 面板的行与列通过分面变量定义。

■ 分面形式: 行分类变量 ~ 列分类变量

```
ggplot(mpg, aes(displ, hwy)) +
  geom_point() +
  facet_grid(drv ~ cyl)
```



# 2. 主题 (theme)

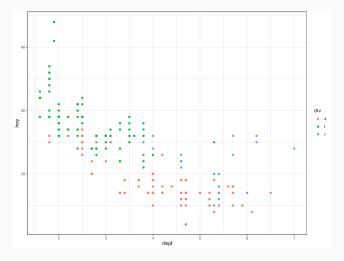
你可以为图形选择不同风格的主题 (外观), ggplot2 提供了 8 套可选主题3:

- theme\_bw()
- theme\_light()
- theme\_classic()
- theme\_gray(): 默认
- theme\_linedraw()
- theme\_dark()
- theme\_minimal()
- theme\_void()

<sup>&</sup>lt;sup>3</sup>也可以用 theme()函数定制自己的主题,更多的主题还有 ggthemes, ggpubr 包,其中包含一些顶级期刊专用绘图主题.

■ 使用或修改主题,只需要添加主题图层

```
ggplot(mpg, aes(displ, hwy, color = drv)) +
  geom_point() +
  theme_bw()
```



## 3. 输出 (output)

■ 用 ggsave()函数,将当前图形保存为想要格式的图形文件,如 png, pdf 等

```
ggsave("my_plot.pdf", width = 8, height = 6, dpi = 300)
```

注:参数 width 和 height 通常只设置其中一个,另一个自动,以保持原图形宽高比。

关于图形中使用中文字体导出到 pdf 等图形文件出现乱码问题的解决办法。

出现中文乱码是因为 R 环境只载入了"sans (Arial)","serif (Times New Roman)","mono (Courier New)"三种英文字体,没有中文字体可用。

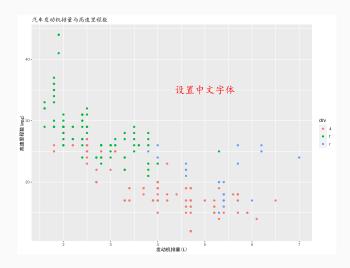
解决办法是用 showtext 包从系统字体中载入中文字体。

- font\_paths(): 查看系统字体路径, windows 默认是 C:\Windows\Fonts
- font\_files(): 查看系统自带的所有字体文件
- font\_add(): 从系统字体中载入字体, 需提供 family 名字,字体 路径

载入字体后,再执行一下 showtext\_auto()(自动启用/关闭功能),就可以使用该字体了。

ggpplot2 中各种设置主题、文本相关的函数 \*\_text(), annotate() 等, 都提供了 family 参数, 设定为 font\_add() 中一致的 family 名字即可。

```
library(showtext)
font_add("heiti", "simhei.ttf")
font add("kaiti", "simkai.ttf")
showtext auto()
ggplot(mpg, aes(displ, hwy, color = drv)) +
 geom_point() +
 theme(axis.title = element_text(family = "heiti"),
       plot.title = element text(family = "kaiti")) +
 xlab(" 发动机排量 (L)") +
 vlab(" 高速里程数 (mpg)") +
 ggtitle("汽车发动机排量与高速里程数")+
  annotate("text", 5, 35, family = "kaiti", size = 8,
          label = " 设置中文字体", color = "red")
ggsave("images/font_example.pdf", width = 7, height = 4)
```



本篇主要参阅 (张敬信, 2022), (Wickham, 2020), (Hadley Wickham, 2017), (王敏杰, 2021), A Practical Introduction to Data Visualization with ggplot2, 模板感谢 (黄湘云, 2021), (谢益辉, 2021).

# 参考文献

Hadley Wickham, G. G. (2017). *R for Data Science*. O' Reilly, 1 edition. ISBN 978-1491910399.

Wickham, H. (2020). ggplot2: Elegant Graphics for Data Analysis. Springer, 3 edition.

张敬信 (2022). R 语言编程: 基于 tidyverse. 人民邮电出版社, 北京.

王敏杰 (2021). 数据科学中的 R 语言. bookdown.org.

谢益辉 (2021). rmarkdown: Dynamic Documents for R.

黄湘云 (2021). Github: R-Markdown-Template.