

R 语言编程：基于 tidyverse

第 19 讲 参数估计

张敬信

2022 年 12 月 6 日

哈尔滨商业大学

- 与总体有关的指标是**参数**；与样本有关的指标，是**统计量**。
- 统计推断的重要内容之一就是**参数估计**，即在抽样及抽样分布的基础上，根据样本统计量来推断所关心的总体参数。

一. 点估计与区间估计

参数估计主要有两种：

- **点估计** (准确/不一定可靠)：就是样本统计量。比如估计哈尔滨成年男性的平均身高，样本均值 175cm 就是点估计；有一定把握落在 172~178cm 之间，就是区间估计。
- **区间估计** (更可靠/不很精确)：通常是指估计其 95% 置信区间，即有 95% 的把握认为该区间包含了总体参数，换句话说，如果抽样 100 次，将有 95 次该区间包含了总体参数。

置信区间的越窄反映了参数估计的精确度越高，影响它因素一是置信水平，置信水平越高置信宽度越大；二是样本量，样本量越大置信宽度越小。

1. 用标准误计算置信区间

即使一个代表性非常好的样本，也是无法真正等同于总体的，总会存在一定的**抽样误差**。

比如用 100 人的平均身高作为总体参数 μ 的估计，如果再随机抽样 100 人，又得到另一个平均身高，再 100 人又一个平均身高，.....做了 10 次抽样，就可以计算出样本统计量：10 个平均身高和 10 个标准差。这 10 个平均身高也可以计算标准差，这就是标准误（样本统计量的标准差），它反映了样本统计量之间差别（抽样误差）的大小。

然而，实际中不可能多次抽样计算每个样本的统计量，再计算各个统计量之间的差异，而是获取一个尽可能大的样本来计算标准误，理论方法是借助统计学家得到的计算公式¹

$$se = s/\sqrt{n}$$

其中， s 为样本标准差， n 为样本量。可见样本量越大，标准误越小。

¹计算具体的标准误时，真正需要的可能是某些真实值或来自总体的值，若无法得到，通常是用它们所对应的样本估计值来代替，某些估计值要保证能作为代替，可能离不开一些模型假定(理论保证)。

标准误几乎在所有统计方法中都会出现，因为标准误的大小直接反映了抽样是否有足够的代表性，进而结果是否有足够的可靠性（可信度）。

由于抽样误差的存在，如果用样本统计量直接估计总体参数，则肯定会有一定的偏差。所以在估计总体参数时需要考虑到这种偏差大小，即用置信区间（参数估计值 \pm 估计误差）来估计总体参数。

根据中心极限定理，从任何分布中抽样，只要样本量足够大，其统计量最终会服从正态分布。因此，估计误差通常用对应一定正态分位数的 Z 值再乘以表示抽样误差的标准误来表示。例如，95% 置信区间一般表示为参数估计值 $\pm 1.96 \times$ 标准误。

不同样本统计量的标准差的计算过程不同，其标准误也不同。

- 均值的置信区间：

$$\bar{x} \pm z_{\alpha/2} \times s/\sqrt{n}$$

- 率的标准差为 $\sqrt{p(1-p)}$ ，故率的置信区间：

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

注 1：若样本量较小，建议用相应 t 值代替 z 值。

注 2：根据容许误差反解 n 就是确定样本量。

2. Bootstrap 法估计置信区间

传统方法依赖于中心极限定理，要求大样本近似正态分布，统计量有计算公式。对于某些抽样分布未知或难以计算的统计量，想要根据一个样本研究抽样样本变化带来的变异，就需要 Bootstrap（自助）重抽样法²。

Bootstrap 法的基本思想是：样本是从总体中随机抽取的，则包含总体的全部信息，那么不妨就把该样本视为“总体”，进行多次有放回抽样生成一系列经验样本，再对每个经验样本计算统计量，就可以得到统计量的分布，进而用于统计推断。

可以证明：**在初始样本量足够大且是从总体中随机抽取的情况下，bootstrap 抽样能够无偏接近总体的分布。**

²Bootstrap 法手工实现极其麻烦，但特别适合用计算机实现，已广泛用于统计推断（点估计/置信区间/假设检验）、回归模型诊断以及机器学习等。

以 Bootstrap 法估计统计量的置信区间为例，基本步骤如下：

- 从原始样本中有放回地随机抽取 n 个构成子样本
- 对子样本计算想要的统计量
- 重复前两步 K 次，得到 K 个统计量的估计值
- 根据 K 个估计值获得统计量的分布，并计算置信区间

tidymodels 系列的 infer 包提供了统一的、tidy 的统计推断工作流，主要函数有：

- `specify()`：设定感兴趣的变量或变量关系
- `hypothesize()`：设定零假设
- `generate()`：基于零假设生成数据
- `calculate()`：根据上述数据，计算统计量的分布
- `visualize()`：可视化

还有获取/绘制 p 值/置信区间的函数。




图 1: 用 `infer` 包实现 Bootstrap 置信区间的一般流程

假设某学校随机抽样了 20 名学生身高，想要估计该学校所有学生平均身高。

- 计算基于标准误的置信区间


```
df = tibble(  
  height = c(167,155,166,161,168,163,179,164,178,156,  
             161,163,168,163,163,169,162,174,172,172))  
mu = mean(df$height) # 点估计：样本均值  
mu  
#> [1] 166  
se = sd(df$height) / sqrt(nrow(df)) # 标准误  
# 基于标准误的置信区间  
c(mu - qnorm(1-0.05/2) * se, mu + qnorm(1-0.05/2) * se)  
#> [1] 163 169
```

- 计算基于 Bootstrap 法的置信区间

```
library(infer)
boot_means = df %>%
  specify(response = height) %>%      # 1000 次 bootstrap
  generate(reps = 1000, type = "bootstrap") %>%
  calculate(stat = "mean")             # 计算统计量：样本均值
boot_means
#> Response: height (numeric)
#> # A tibble: 1,000 x 2
#>   replicate stat
#>       <int> <dbl>
#> 1           1  165.
#> 2           2  166.
#> 3           3  166.
#> # ... with 997 more rows
```

```
boot_ci = boot_means %>%                                # bootstrap 置信区间
  get_ci(level = 0.95, type = "percentile")
boot_ci
#> # A tibble: 1 x 2
#>   lower_ci upper_ci
#>   <dbl>     <dbl>
#> 1    163.     169

visualize(boot_means) +
  shade_ci(endpoints = boot_ci)                          # 可视化
```



注：更多案例可参阅 `infer` 包 Vignettes, ([Chester Ismay, 2018](#)), ([Mine Çetinkaya Rundel, 2021](#)).

二. 最小二乘估计 (OLS)


最小二乘估计 (Ordinary Least Squares), 常用于估计线性回归、曲线拟合的参数, 其思想是让实际值与模型预测值的总偏离达到最小, 从而得到最优的模型参数估计值。

用一元线性回归来阐述, 比如有 10 组广告费用与销售额的数据:

```
sales = tibble(  
  cost = c(30,40,40,50,60,70,70,70,80,90),  
  sale = c(143.5,192.2,204.7,266,318.2,457,333.8,312.1,  
          386.4,503.9))
```


- 绘制散点图:

```
ggplot(sales, aes(cost, sale)) + geom_point()
```



这些散点大致在一条直线上，一元线性回归就是寻找一条直线，使得与这些散点拟合程度最好（越接近直线越好）：

```
m = lm(sale ~ cost, sales)
sales1 = sales[c(6,9),] %>%
  mutate(p = predict(m, .))
ggplot(sales, aes(cost, sale)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  geom_segment(aes(x = cost, y = sale,
                  xend = cost, yend = p),
              data = sales1, linetype = 2, color = "red")
```



这样一条直线（一元线性回归模型）方程可写为：

$$y = \beta_0 + \beta_1 x$$

其中, β_0, β_1 为待定参数, 目标是找到样本点最接近的直线对应的 β_0, β_1 .

▪ 怎么刻画这种“最接近”？

$\hat{y}_i = \beta_0 + \beta_1 x_i$ 是与横轴 x_i 对应的直线上的点的纵坐标（模型预测值），它与样本点 x_i 对应的真实值 y_i 之差，就是预测误差（红虚线长度）：

$$\varepsilon_i = |y_i - \hat{y}_i|, \quad i = 1, \dots, n$$

适合描述散点到直线的“接近程度”。

但绝对值不容易计算，改用：

$$\varepsilon_i^2 = (y_i - \hat{y}_i)^2, \quad i = 1, \dots, n$$

要让所有散点总体上最接近该直线，就是让总的预测误差：

$$J(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$

最小。

于是，问题转化为优化问题：

$$\arg \min_{\beta_0, \beta_1} J(\beta_0, \beta_1) = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$

其中， $\arg \min$ 意思是求右式达到最小时所对应的参数 β_0, β_1 。这就是“最小二乘法”，有着很直观的几何解释。

这是求二元函数极小值问题。根据微积分知识，二元函数极值是在一阶偏导等于 0 点处取到：

$$\begin{cases} \frac{\partial J}{\partial \beta_0} = -2 \sum_{i=1}^n [y_i - \beta_0 - \beta_1 x_i] = 0 \\ \frac{\partial J}{\partial \beta_1} = -2 \sum_{i=1}^n [y_i - \beta_0 - \beta_1 x_i] x_i = 0 \end{cases}$$

解关于 β_0, β_1 的二元一次方程组得

$$\begin{cases} \beta_0 = \bar{y} - \beta_1 \bar{x} \\ \beta_1 = \frac{\sum_{i=1}^n x_i y_i - \bar{y} \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{cases}$$

其中,

$$\begin{cases} \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \\ \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \end{cases}$$

更一般地，多元线性回归、非线性回归（拟合）的最小二乘法估计待定参数，也是类似的，只需要将线性预测值改成模型预测值：

$$\arg \min_{\beta} J(\beta) = \sum_{i=1}^n [y_i - f(x_i, \beta)]^2$$

线性回归的最小二乘估计可用 `lm()` 函数实现，非线性回归的最小二乘估计可用 `nls()` 函数实现。

案例：非线性拟合

- 现有我国 2003-2019 年历年累计电影票房数据：

```
df = readxl::read_xlsx("data/历年累计票房.xlsx") %>%  
  mutate(年份 = 年份 - 2002)
```

```
df
```

```
#> # A tibble: 17 x 2
```

```
#>   年份  累计票房
```

```
#>   <dbl>    <dbl>
```

```
#> 1      1      8
```


```
#> 2      2     9.2
```

```
#> 3      3    15.1
```

```
#> # ... with 14 more rows
```



```
p = ggplot(df, aes(年份, 累计票房)) +  
  geom_point(color = "red", size = 1.5)  
p
```



非线性回归第一步是找到合适的模型函数。这些散点大致服从 Logistic 分布曲线：

$$N(t) = \frac{\varphi_1}{1 + e^{-(\varphi_2 + \varphi_3 t)}}$$

我们想用 `nls()` 做非线性拟合，寻找最优的参数值： $\varphi_1, \varphi_2, \varphi_3$ 。

非线性拟合的算法非常依赖于参数初始值的选取，选取适当（离估计值不远）很快就能收敛到最优估计，否则迭代很可能无法收敛。

参数 φ_1 对应人口容纳量上限，大致为曲线拐点值（目测约为 400）的 2 倍。一旦确定了 φ_1 ，则

$$\text{logit}\left(\frac{N(t)}{\varphi_1}\right) = \varphi_2 + \varphi_3 t$$

其中， $\text{logit}(p) = \ln \frac{p}{1-p}$ 称为 Logit 变换。

于是，用 `lm()` 做线性回归即可得到 φ_2, φ_3 的估计值。

```
lm.fit = lm(car::logit(累计票房 / 800) ~ 年份, df)
coef(lm.fit)
#> (Intercept)          年份
#>      -5.145         0.391
```

这样就得到了一组较好的参数初始值：


$$\varphi_1 = 800, \varphi_2 = -5.14, \varphi_3 = 0.39$$

接着，用 `nls()` 做非线性拟合，需要提供模型公式和初始参数值：

```
log.fit = nls(累计票房 ~ phi1 / (1+exp(-(phi2+phi3*年份))),  
              data = df,  
              start = list(phi1=800, phi2=-5.14, phi3=0.39))  
coefs = coef(log.fit)  
coefs  
#>      phi1      phi2      phi3  
#> 760.577 -5.457  0.427
```

绘图看拟合效果，同时这也是已知函数表达式，绘制 `ggplot` 图形的方法：

```
LogFit = function(x) coefs[1] / (1+exp(-(coefs[2]+coefs[3]*  
p + geom_function(fun=LogFit, color="steelblue", size=1.2))
```



注: `nls()` 拟合依赖于初始值和 `selfstart` 设置, 容易拟合失败, 若失败可以用 `gslnls` 包。

三. 最大似然估计 (MLE)

最大似然估计 (Maximum Likelihood Estimation) 是频率学派常用的方法，其思想是既然抽取到现在的样本数据，那么最优的模型参数应选择这样的值：让这些样本数据最有可能出现！

比如，你和猎人同时开枪，结果是猎物被击中。用最大似然估计：猎物是猎人打中的，而不是你打中的！因为猎人打中的概率比你大。

假设数据 x_1, x_2, \dots, x_n 是独立同分布的一组抽样, 记 $\mathbf{x} = (x_1, x_2, \dots, x_n)$, 则最大似然法估计参数 θ , 可推导如下:

$$\begin{aligned}\hat{\theta}_{\text{MLE}} &= \arg \max P(\mathbf{x} \mid \theta) \\ &= \arg \max P(x_1 \mid \theta) P(x_2 \mid \theta) \cdots P(x_n \mid \theta) \\ &= \arg \max \ln \prod_{i=1}^n P(x_i \mid \theta) \\ &= \arg \max \sum_{i=1}^n \ln P(x_i \mid \theta)\end{aligned}$$

其中, 第 1 行到第 2 行是由于独立同分布; 第 2 行到第 3 行是由于 $\ln(\cdot)$ 单调递增, 故做对数变换不影响求最大参数值。

最后要优化的函数记为

$$\mathcal{L}(\theta \mid X) = \sum_{i=1}^n \ln P(x_i \mid \theta)$$

称为对数似然函数，其中， $P(x_i \mid \theta)$ 为给定的 θ 下出现 x_i 的概率（离散情形是概率，连续情形是概率密度）。

于是，最大似然估计的一般步骤：先推导出对数似然函数，再做最大化寻优即可。后一步可用自带的 `optimize()` 函数，或者 `maxLik` 包中的 `maxLik()` 函数来实现。

案例：离散情形，估计伯努利分布参数

例如，已发生事件是：抛 10 次硬币，出现 3 次正面，用最大似然法估计参数 $p = P(\text{正})$.

抛硬币服从伯努利分布，该事件发生的概率（似然函数）可表示为：

$$P(x | p) = C_{10}^3 p^3 (1 - p)^7$$

从而，对数似然函数为

$$\mathcal{L}(p | x) = \ln C_{10}^3 + 3 \ln p + 7 \ln(1 - p)$$

注意第一项是常数，不妨忽略掉它，不影响优化目标。

用 maxLik 包实现, 先定义对数似然函数:

```
loglik = function(p) 3 * log(p) + 7 * log(1-p)
```

再调用 maxLik() 函数, 需传递对数似然函数, 并提供迭代初始值:

```
library(maxLik)
m = maxLik(loglik, start = 0.5)
coef(m)          # 最优参数估计值
#> [1] 0.3
stdEr(m)         # 估计的标准误
#> [1] 0.145
```

不出所料, 最优估计 $\hat{p} = 0.3$, 就是正面出现的频率!

案例：连续情形，估计正态分布参数

离散情形，用的是单个点的概率；连续情形，单个点的概率为 0，考虑包含点的任意小区间段的概率才有意义，也就是概率密度：

$$f(x_0) = \lim_{\delta \rightarrow 0} \frac{P(X \in [x_0 - \delta, x_0 + \delta])}{2\delta}$$

以 `mtcars$mpg` 数据 ($n=32$) 为例，用最大似然法估计正态分布的参数 μ, σ^2 。该数据出现的概率（似然函数）为：

$$\begin{aligned} f(x \mid \mu, \sigma) &= \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2\sigma^2}(x - \mu)^2 \right] \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2\sigma^2}(x_i - \mu)^2 \right] \\ &= (2\pi)^{-n/2} (\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right] \end{aligned}$$

从而，对数似然函数为：

$$\mathcal{L}(\mu, \sigma \mid \mathbf{x}) = -\frac{n}{2} \ln(2\pi) - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$


同样忽略掉第一项常数，定义对数似然函数，再调用 `maxLik()` 寻优：

```
loglik = function(theta) {  
  mu = theta[1]  
  sigma = theta[2]  
  n = nrow(mtcars)  
  - n*log(sigma) - 1/(2*sigma^2) * sum((mtcars$mpg-mu)^2)  
}
```

```
m = maxLik(loglik, start=c(mu=30, sigma=10))  
coef(m)          # 最优参数估计值  
#>      mu sigma  
#> 20.09  5.93  
stdEr(m)         # 估计的标准误  
#>      mu sigma  
#> 1.049 0.744
```

- 可视化估计的效果:

```
ggplot(mtcars, aes(mpg)) +  
  geom_histogram(binwidth = 1, fill = "steelblue") +  
  stat_function(fun = ~ dnorm(.x, mean=20.09, sd=5.93) * 32,  
               color = "red", size = 1.2)
```



实际上，正态分布两个参数的最大似然估计分别为：

$$\hat{\mu} = \bar{\mathbf{x}}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{\mathbf{x}})^2.$$

案例：线性回归系数的最大似然估计

真实数据中，一组 x 值对应的 y 观测值可以看作是来自真实 y 值的一次抽样，因为 y 值可能受多种因素的影响，故可以假设任意一组 x 值对应的真实 y 值是服从正态分布的随机变量。

想要找到最优的回归系数，根据最大似然估计的思想，最优的回归系数就是让 y 观测值出现的概率最大时所对应的回归系数。

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n$$

其中， ε_i 为预测误差，即不能被线性模型刻画的部分。根据线性回归模型假设： ε_i 独立同分布于 $N(0, \sigma^2)$ ，否则说明数据不适合用线性回归模型建模。

由正态分布的性质, $y_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, 从而在 x_i, β 已知的条件下, y_i 的概率密度为:

$$f(y_i | x_i, \beta) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{[y_i - (\beta_0 + \beta_1 x_i)]^2}{2\sigma^2}\right), \quad i = 1, \dots, n$$

从而, 所有 y 的观测数据出现的概率 (似然函数) 为:

$$\begin{aligned} f(\mathbf{y} | \mathbf{x}, \beta) &= \prod_{i=1}^n f(y_i | x_i, \beta) \\ &= \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{[y_i - (\beta_0 + \beta_1 x_i)]^2}{2\sigma^2}\right) \right] \end{aligned}$$

于是，对数似然函数为：

$$\begin{aligned}\mathcal{L}(\beta_0, \beta_1 \mid \mathbf{x}) &= \ln(f(\mathbf{y} \mid \mathbf{x}, \beta)) \\ &= n \ln\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \sum_{i=1}^n \frac{[y_i - (\beta_0 + \beta_1 x_i)]^2}{2\sigma^2}\end{aligned}$$

注意，要做的是选取 β_0, β_1 让上式达到最小，第一项以及第二项中的 $2\sigma^2$ 不起作用。故最大化该对数似然函数，就等价于：

$$\arg \min_{\beta_0, \beta_1} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$

这与最小二乘估计是等价的！

最后注：maxLik() 函数在优化时，默认是根据数据计算数值梯度（只适合简单问题），若推导出梯度（甚至是 Hessian 矩阵）的解析式，并提供给相应参数，则估计速度更快、结果更稳定。

四. 贝叶斯：最大后验估计

先来介绍一下频率学派与贝叶斯学派³，频率学派和贝叶斯学派对世界的认知有本质不同：

- 频率学派认为世界是确定的，有一个本体，这个本体的真值是不变的，我们的目标是要找到这个真值或真值所在的范围；
- 而贝叶斯学派认为世界是不确定的，人们对世界先有一个预判，而后通过观测数据对这个预判做调整，我们的目标是要找到最优的描述这个世界的概率分布。

³引用自夏飞知乎：聊一聊机器学习的 MLE 和 MAP：最大似然估计和最大后验估计。

在对数据建模时，用 θ 表示模型的参数，解决问题的本质就是求 θ ：

- **频率学派认为：存在唯一真值 θ**

比如抛硬币抛一枚硬币 100 次，有 20 次正面朝上，要估计抛硬币正面朝上的概率，即伯努利分布的参数 $p = P(\text{正})$ 。

在频率学派看来， $p = 20/100 = 0.2$ ，简单直观。当抛硬币次数趋于无穷时，该方法能给出精确的估计；然而次数不够大时，可能会产生严重的偏差。

- 贝叶斯学派认为： θ 是一个随机变量，符合一定的概率分布

在贝叶斯学派里有两大输入和一大输出，输入是先验 (prior) 和似然 (likelihood)，输出是后验 (posterior)。

先验，即 $P(\theta)$ ，是指在没有观测到任何数据时对 θ 的预先判断，比如抛一枚硬币，一种可行的先验是认为该硬币有较大概率是均匀的；似然，即 $P(X|\theta)$ ，是假设 θ 已知后观察到的数据应该是什么样子的；

后验，即 $P(\theta|X)$ ，是最终的参数分布。

贝叶斯估计的基础是贝叶斯公式：

$$P(\theta|X) = \frac{P(X|\theta)P(\theta)}{P(X)}$$

同样是抛硬币，对一枚均匀硬币抛 5 次得到 5 次正面，如果先验认为该硬币大概率是均匀的，那么参数 p ，即 $P(\theta|X)$ ，是一个概率分布，最大值会介于 0.5~1 之间，而不是武断地认为 $p = 1$ 。

随着数据量的增加，参数分布会越来越向数据靠拢，先验的影响力会越来越小；如果先验是均匀分布（本质上表示对事物没有任何预判），则贝叶斯方法等价于频率方法。

贝叶斯统计也越来越兴起，特别是出现了专门用于贝叶斯推断的 Stan 语言，其与 R 语言的接口是 rstan 包，以及更方便的统计建模包：rstanarm，brms，tidybayes 等。

最大后验估计

贝叶斯学派常用的估计方法，同样假设数据 x_1, x_2, \dots, x_n 是独立同分布的一组抽样，记 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ ，则最大后验估计参数 θ ，其推导基于贝叶斯公式：

$$\begin{aligned}\hat{\theta}_{\text{MAP}} &= \arg \max P(\theta \mid \mathbf{x}) \\ &= \arg \max \ln P(\theta \mid \mathbf{x}) \\ &= \arg \max \ln P(\mathbf{x} \mid \theta) + \ln P(\theta) - \ln P(\mathbf{x}) \\ &= \arg \max \ln P(\mathbf{x} \mid \theta) + \ln P(\theta)\end{aligned}$$

可见，与最大似然估计的不同在于相差一个先验 $\ln(P(\theta))$ 。有趣的是，若该先验是正态分布，MAP 等价于 MLE+L2 正则。

本篇主要参阅 (张敬信, 2022), (冯国双, 2018), 以及包文档, 模板感谢 (黄湘云, 2021), (谢益辉, 2021).

参考文献

Chester Ismay, A. Y. K. (2018). *Statistical Inference via Data Science A Modern Dive into R and the Tidyverse*. CRC.

Mine Çetinkaya Rundel, J. H. (2021). *Introduction to Modern Statistics*. CRC, 1 edition.

冯国双 (2018). 白话统计. 电子工业出版社, 北京, 1 edition.

张敬信 (2022). *R 语言编程: 基于 tidyverse*. 人民邮电出版社, 北京.

谢益辉 (2021). *rmarkdown: Dynamic Documents for R*.

黄湘云 (2021). *Github: R-Markdown-Template*.